

Grupa: [Machnik Dominik, Paśko Oskar]

Wybrany temat: [T2]

Linki: [<https://github.com/oskarpasko/aipo-project>]

Status: [„Czekamy na feedback odnośnie projektu”]

Podejście

Poszczególne etapy:

1. Reprezentacja danych

Mapa głębi z UR Fall Detection Dataset. Testowane cztery kodowania:

- raw depth – surowa mapa głębi powielona do 3 kanałów
- colormap – mapa głębi znormalizowana i zakodowana mapą kolorów JET
- surface normals – wektory normalne obliczone z gradientów mapy głębi
- HHA – reprezentacja H (height), H(angle), D (disparity)

2. Strategia analizy sekwencji w czasie

Analiza pojedynczych klatek (frame-based). Każda klatka traktowana jako niezależna próbka – brak agregacji czasowej i modeli wideo.

3. Model bazowy

Modelem bazowym jest ResNet-18 z warstwą końcową dostosowaną do klasyfikacji binarnej (fall / nofall).

4. Setup treningu

- Loss: CrossEntropyLoss
- Optymalizator: Adam
- Learning rate: 1e-3
- Batch size: 8
- Liczba epok: 5
- Fine-tuning całej sieci

5. Metryki klasyfikacji

- Accuracy
- Precision
- Recall
- F1-score oraz Confusion Matrix

Co odróżnia rozwiązanie od innych grup:

- Porównanie kilku kodowań mapy głębi w jednym, spójnym pipeline.
- Wykorzystanie surface normals oraz HHA zamiast wyłącznie surowej głębi.
- Identyczny model i setup treningu dla wszystkich reprezentacji.
- Skupienie na wpływie reprezentacji danych, a nie zmianach architektury.

Dane i przygotowanie

- **Zbiór danych / podział:**
 - Zbiór treningowy to około 70-80% dostępnych klatek
 - Zbiór walidacyjny to około 20-30% dostępnych klatek.
 - Zbiór testowy nie został wydzielony, ewaluacja przeprowadzana jest na zbiorze walidacyjnym
- **Preprocessing:**
 - Konwersja map głębi do reprezentacji 3-kanałowej
 - Resize do 224x224
 - Normalizacja zgodna z ImageNet (mean, std)

Wyniki na dziś

Ewaluacja została przeprowadzona na zbiorze walidacyjnym, który pełni również rolę zbioru porównawczego do analizy wpływu różnych kodowań mapy głębi.

Kodowanie	Accuracy	Precision	Recall	F1-score
Raw	1,000	1,000	1,000	1,000
Colormap	0.646	0.583	1.000	1.000
Normals	1.000	1.000	1.000	1.000
HHA	0.919	0.860	1.000	0.925

Najlepsze wyniki uzyskano dla kodowań raw depth oraz surface normals, jednak mogą one wskazywać na ograniczoną generalizację. Kodowanie HHA zapewnia bardziej zrównoważone wyniki, natomiast colormap generuje dużą liczbę fałszywych alarmów.

Ewentualne TODO

- Dodanie dodatkowego zbioru testowego do projektu.
- Zwiększenie liczby próbek
- „Zabawa” parametrami modelu / sieci